Tecnologia Criptográfica

29 de Novembro de 2020

Trabalho Prático 1

a83899	André Morais
a84485	Tiago Magalhães

Decifragem de Criptogramas com Cifras Clássicas

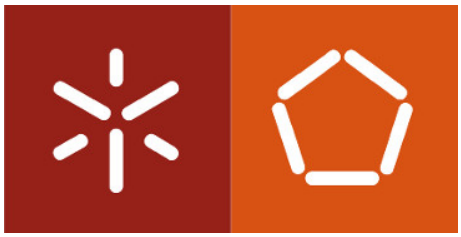

Mestrado Integrado em Engenharia Informática
Universidade do Minho

Conteúdo

1 Introdução

No âmbito da Unidade Curricular de Tecnologia Criptográfica, foi nos proposto que decifrasse-mos três criptogramas cifrados com as cifras *affine*, de substituição, e Vigenère sem se saber a qual dos criptogramas correspondia cada cifra.

2 Estratégia de resolução

Através da informação fornecida pelo enunciado, sabemos que os textos cifrados correspondem a textos limpos escritos no idioma inglês, deste modo o criptograma cifrado com a cifra de Vigenère, através de análise de frequências será o que terá menos semelhanças com a distribuição mais provável das letras de um texto em inglês, dado que neste tipo de cifra uma palavra pode ocorrer cifrada de diferentes maneiras, devido à existência de uma chave e sua periodicidade, periodicidade esta que pode gerar padrões, porém serão menos comuns em relação às outras cifras. Já para as cifras *affine* e de substituição a maneira de as atacar é através de análise de frequências.

A cifra *affine* corresponde a uma cifra de substituição onde o texto limpo é mapeado através de uma função afim, logo ambas irão ter uma distribuição parecida à da língua inglesa, uma vez que cada letra irá aparecer no texto sempre na forma da mesma letra com a qual foi substituída ocorrendo desta maneira padrões.

E	12.02
T	9.10
A	8.12
O	7.68
I	7.31
N	6.95
S	6.28
R	6.02
H	5.92
D	4.32
L	3.98
U	2.88
C	2.71
M	2.61
F	2.30
Y	2.11
W	2.09
G	2.03
P	1.82
B	1.49
V	1.11
K	0.69
X	0.17
Q	0.11
J	0.10
Z	0.07

(a) Frequência de letras em inglês

```
Número de Caracteres:

('Z', 128, 5.069306930693069)
('J', 120, 4.752475247524752)
('Y', 120, 4.752475247524752)
('D', 114, 4.5148514851485148)
('P', 103, 4.079207920792079)
('C', 101, 4.0)
('Q', 96, 3.801980198019802)
('W', 93, 3.683168316831683)
('R', 89, 3.5247524752475243)
('H', 88, 3.4851485148514856)
('M', 85, 3.3663366336633667)
('L', 83, 3.2871287128712874)
('N', 77, 3.0495049504950495)
('G', 75, 2.9702970297029703)
('T', 74, 2.9306930693069306)
('F', 73, 2.8910891089108914)
('O', 72, 2.851485148514852)
('X', 67, 2.6534653465346536)
('V', 59, 2.3366336633663365)
('I', 54, 2.1386138613861387)
('S', 54, 2.1386138613861387)
('B', 47, 1.8613861386138613)
('E', 47, 1.8613861386138613)
('K', 42, 1.6633663366336635)
('U', 41, 1.6237623762376239)
('A', 39, 1.5445544554454446)
```

(b) Frequência de letras criptograma 1

Figura 1: Resultados da aplicação de análise de frequência de letras a cada criptograma

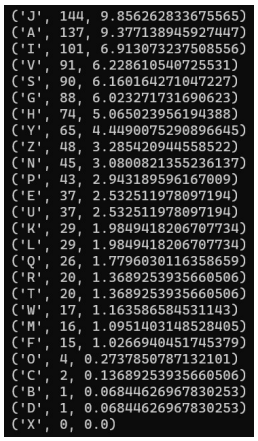

(a) Frequência de letras criptograma 2

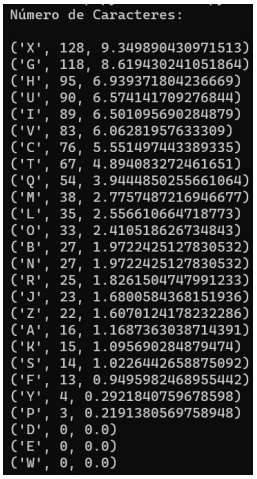

(b) Frequência de letras criptograma 3

Figura 2: Resultados da aplicação de análise de frequência de letras a cada criptograma

Com os resultados demonstrados nas **Figuras 1 e 2**, podemos observar que o primeiro criptograma apresenta uma maior diferença para uma distribuição normal de letras em inglês, por isso corresponderá ao ao criptograma cifrado com a cifra de Vigenère. Desta forma, resta assim distinguir dois criptogramas, para a sua distinção, aplicamos a nossa estratégia para decifragem de um criptograma correspondente à cifra *affine* e vimos qual retornava texto legível uma vez que não podíamos fazer isto usando a cifra de substituição, pois a de *affine* corresponde a uma de substituição e o contrário não.

2.1 Cifra Afim

A primeira abordagem para decifrar criptogramas com este tipo de cifra que pensamos foi *brute-force*, uma vez, que esta cifra apresenta um conjunto de chaves pequeno, dado que, a função de cifragem corresponde a $E(x) = (ax + b) \mod m$, em que m é o tamanho do alfabeto no caso destes criptogramas é 26 (apenas as letras se encontram cifradas) e a tem de ser um co-primo[1] com $m(26)$, desta forma $a \in \{1, 3, 5, 7, 9, 11, 15, 17, 19, 21, 23, 25\}$ e $0 \leqslant b \leqslant 25$.

Portanto, existem 12 números que são co-primos com 26 e que são menores que este. Para cada valor de a existem 26 possíveis *shift's* (valor de b), portanto existem $12 * 26$ ou 312 possíveis chaves.

De maneira a otimizar-mos este processo, sabendo que os criptogramas apresentam espaços e que a palavra *the* é das mais frequentes em inglês, consequentemente aplicamos uma heurística que verifica a palavra mais frequente com três letras nos criptogramas e com base neste palpite associamo-la a *the* e com isto tiramos os valores de a e b. Para decifrar-mos tivemos de usar a seguinte equação: $D(x) = a^{-1}(x - b) \mod m$, onde a^{-1} é a inversa da multiplicação modular e que satisfaz a equação $1 = aa^{-1} \mod m$

Resultado da chave obtida ($D(x) = (11x + 8) \mod 26$)

A	**B**	**C**	**D**	**E**	**F**	**G**	**H**	**I**	**J**	**K**	**L**	**M**	**N**	**O**	**P**	**Q**	**R**	**S**	**T**	**U**	**V**	**W**	**X**	**Y**	**Z**
8	13	18	23	2	7	12	17	22	1	6	11	16	21	0	5	10	15	20	25	4	9	14	19	24	3
I	**N**	**S**	**X**	**C**	**H**	**M**	**R**	**W**	**B**	**G**	**L**	**Q**	**V**	**A**	**F**	**K**	**P**	**U**	**Z**	**E**	**J**	**O**	**T**	**Y**	**D**

Figura 3: Tabela de substituição

[1] conjunto de números onde o único divisor comum a todos eles é o número 1.

Com isto sabemos que o criptograma associado a esta cifra é:

SJ SY VGJ JGG KUEH JG NACUSNA JHIJ QHIJ JHA QSYAYJ GL KIVOSVP, JHGYA QHG INA TAYJ AVJSJZAP JG JNUYJ JHASN GQV DUPWKAVJ, LSVP VAEAYYINM JG QINNIVJ JHASN NAZMSVW GV SJ, YHGUZP TA YUTKSJJAP JG TM JHIJ KSYEAZZIVAGUY EGZZAEJSGV GL I LAQ QSYA IVP KIVM LGGZSYH SVPSFSPUIZY, EIZZAP JHA RUTZSE. JHA KGYJ SVJGZANIVJ GL EHUNEHAY, JHA NGKIV EIJHGZSE EHUNEH, AFAV IJ JHA EIVGVSYIJSGV GL I YISVJ, IPKSJY, IVP ZSYJAVY RIJSAVJZM JG, I "PAFSZ'Y IPFGEIJA."JHA HGZSAYJ GL KAV, SJ IRRAINY, EIVVGJ TA IPKSJJAP JG RGYJHUKGUY HGVGUNY, UVJSZ IZZ JHIJ JHA PAFSZ EGUZP YIM IWISVYJ HSK SY OVGQV IVP QASWHAP. SL AFAV JHA VAQJGVSIV RHSZGYGRHM QANA VGJ RANKSJJAP JG TA CUAYJSGVAP, KIVOSVP EGUZP VGJ LAAZ IY EGKRZAJA IYYUNIVEA GL SJY JNUJH IY JHAM VGQ PG. JHA TAZSALY QHSEH QA HIFA KGYJ QINNIVJ LGN, HIFA VG YILAWUINP JG NAYJ GV, TUJ I YJIVPSVW SVFSJIJSGV JG JHA QHGZA QGNZP JG RNGFA JHAK UVLGUVPAP. SL JHA EHIZZAVWA SY VGJ IEEARJAP, GN SY IEEARJAP IVP JHA IJJAKRJ LISZY, QA INA LIN AVGUWH LNGK EANJISVJM YJSZZ; TUJ QA HIFA PGVA JHA TAYJ JHIJ JHA ABSYJSVW YJIJA GL HUKIV NAIYGV IPKSJY GL; QA HIFA VAWZAEJAP VGJHSVW JHIJ EGUZP WSFA JHA JNUJH I EHIVEA GL NAIEHSVW UY: SL JHA ZSYJY INA OARJ GRAV, QA KIM HGRA JHIJ SL JHANA TA I TAJJAN JNUJH, SJ QSZZ TA LGUVP QHAV JHA HUKIV KSVP SY EIRITZA GL NAEASFSVW SJ; IVP SV JHA KAIVJSKA QA KIM NAZM GV HIFSVW IJJISVAP YUEH IRRNGIEH JG JNUJH, IY SY RGYYSTZA SV GUN GQV PIM. JHSY SY JHA IKGUVJ GL EANJISVJM IJJISVITZA TM I LIZZSTZA TASVW, IVP JHSY JHA YGZA QIM GL IJJISVSVW SJ.

E o texto decifrado corresponde a:

it is not too much to require that what the wisest of mankind, those who are best entitled to trust their own judgment, find necessary to warrant their relying on it, should be submitted to by that miscellaneous collection of a few wise and many foolish individuals,called the public. the most intolerant of churches, the roman catholic church, even at the canonisation of a saint, admits, and listens patiently to, a "devil's advocate."the holiest of men, it appears,cannot be admitted to post humous honours, until all that the devil could say against him is known and weighed. if even the newtonian philosophy were not permitted to be questioned, man kind could not feelas complete assurance of its truth as they now do. the beliefs which we have most warrant for, have no safeguard to rest on, but a standing invitation to the whole world to prove them unfounded. if the challenge is not accepted, or is accepted and the attempt fails, weare far enough from certainty still; but we have done the best thatthe existing state of human reason admits of; we have neglected nothing that could give the truth a chance of reaching us: if the lists are kept open, we may hope that if there be a better truth, it will be found when the human mind is capable of receiving it; and in the meantime we may rely on having attained such approach to truth, as is possible in our own day. this is the amount of certainty attainable by a fallible being, and this the sole way of attaining it.

2.2 Cifra de Substituição

Como o o resultado obtido para cifra *affine* foi o criptograma 2, resta apenas o criptograma 3 que irá corresponder à cifra de substituição.

Para esta cifra não podemos pensar num ataque do tipo *brute-force*, pois o conjunto de chaves é grande, ou seja, 26!.

Esta decifragem foi a mais direta, isto é, apenas tivemos de descobrir a que letra correspondia cada letra. A nossa intuição foi contabilizar, a partir do criptograma 3, o número de vezes que cada palavra aparecia.

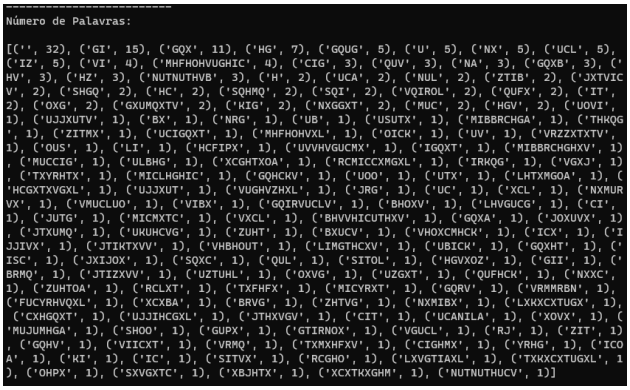

Word	Parts of speech	OEC rank
the	Article	1
be	Verb	2
to	Preposition	3
of	Preposition	4
and	Conjunction	5
a	Article	6
in	Preposition	7
that	Conjunction et al.	8
have	Verb	9
I	Pronoun	10
it	Pronoun	11
for	Preposition	12

Figura 4: Frequência das palavras no criptograma

Pelas imagens apresentadas em cima, podemos perceber que a palavra mais frequente em inglês é a palavra *the*, e por isso deduzimos que a palavra com 3 letras mais frequente iria corresponder ao *the*, que neste caso era a palavra **GQX**. O próximo passo foi encontrar palavras com as letras **GQX** como por exemplo **GQXB** e ir substituindo de acordo com a lista[1].

Sendo assim aplicamos um processo iterativo, depois de algumas trocas concluímos que a tabela apresentada na Figura 5 representa a nossa "chave"

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z
U	N	M	L	X	Z	K	Q	H	-	P	O	B	C	I	J	Y	T	V	G	R	F	S	-	A	-

Figura 5: Tabela de substituição

Com isto sabemos que o criptograma associado a esta cifra é:

HG UOVI UJJXUTV VI GI BX, NRG H UB CIG USUTX GQUG UCA MIBBRCHGA QUV U THKQG GI ZITMX UCIGQXT GI NX MHFHOHVXL. VI OICK UV GQX VRZZXTXTV NA GQX NUL OUS LI CIG HCFIPX UVVHVGUCMX ZTIB IGQXT MIBBRCHGHXV, H MUCCIG ULBHG GQUG JXTVICV XCGHTXOA RCMICCXMGXL SHGQ GQXB IRKQG GI VGXJ HC UCL TXYRHTX GQUG U MICLHGHIC IZ GQHCKV SHGQ SQHMQ UOO SQI UTX LHTXMGOA HCGXTXVGXL UJJXUT GI NX VUGHVZHXL, VQIROL NX JRG UC XCL GI NXMURVX HG HV U VMUCLUO GI JXTVICV VIBX GQIRVUCLV IZ BHOXV LHVGUCG, SQI QUFX CI JUTG IT MICMXTC HC HG. OXG GQXB VXCL BHVVHICUTHXV, HZ GQXA JOXUVX, GI JTXUMQ UKUHCVG HG; UCL OXG GQXB, NA UCA ZUHT BXUCV (IZ SQHMQ VHOXCMHCK GQX GXUMQXTV HV CIG ICX), IJJIVX GQX JTIKTXVV IZ VHBHOUT LIMGTHCXV UBICK GQXHT ISC JXIJOX. HZ MHFHOHVUGHIC QUV KIG GQX NXGGXT IZ NUTNUTHVB SQXC NUTNUTHVB QUL GQX SITOL GI HGVXOZ, HG HV GII BRMQ GI JTIZXVV GI NX UZTUHL OXVG NUTNUTHVB, UZGXT QUFHCK NXXC ZUHTOA KIG RCLXT, VQIROL TXFHFX UCL MICYRXT MHFHOHVUGHIC. U MHFHOHVUGHIC GQUG MUC GQRV VRMMRBN GI HGV FUCYRHVQXL XCXBA, BRVG ZHTVG QUFX NXMIBX VI LXKXCXTUGX, GQUG CXHGQXT HGV UJJIHCGXL JTHXVGV UCL GXUMQXTV, CIT UCANILA XOVX, QUV GQX MUJUMHGA, IT SHOO GUPX GQX GTIRNOX, GI VGUCL RJ ZIT HG. HZ GQHV NX VI, GQX VIICXT VRMQ U MHFHOHVUGHIC TXMXHFXV CIGHMX GI YRHG, GQX NXGGXT. HG MUC ICOA KI IC ZTIB NUL GI SITVX, RCGHO LXVGTIAXL UCL TXKXCXTUGXL (OHPX GQX SXVGXTC XBJHTX) NA XCXTKXGHM NUTNUTHUCV.

E o texto decifrado corresponde a:

IT ALSO APPEARS SO TO ME, BUT I AM NOT AWARE THAT ANY COMMUNITY HAS A RIGHT TO FORCE ANOTHER TO BE CIVILISED. SO LONG AS THE SUFFERERS BY THE BAD LAW DO NOT INVOKE ASSISTANCE FROM OTHER COMMUNITIES, I CANNOT ADMIT THAT PERSONS ENTIRELY UNCONNECTED WITH THEM OUGHT TO STEP IN AND REQUIRE THAT A CONDITION OF THINGS WITH WHICH ALL WHO ARE DIRECTLY INTERESTED APPEAR TO BE SATISFIED, SHOULD BE PUT AN END TO BECAUSE IT IS A SCANDAL TO PERSONS SOME THOUSANDS OF MILES DISTANT, WHO HAVE NO PART OR CONCERN IN IT. LET THEM SEND MISSIONARIES, IF THEY PLEASE, TO PREACH AGAINST IT; AND LET THEM, BY ANY FAIR MEANS (OF WHICH SILENCING THE TEACHERS IS NOT ONE), OPPOSE THE PROGRESS OF SIMILAR DOCTRINES AMONG THEIR OWN PEOPLE. IF CIVILISATION HAS GOT THE BETTER OF BARBARISM WHEN BARBARISM HAD THE WORLD TO ITSELF, IT IS TOO MUCH TO PROFESS TO BE AFRAID LEST BARBARISM, AFTER HAVING BEEN FAIRLY GOT UNDER, SHOULD REVIVE AND CONQUER CIVILISATION. A CIVILISATION THAT CAN THUS SUCCUMB TO ITS VANQUISHED ENEMY, MUST FIRST HAVE BECOME SO DEGENERATE, THAT NEITHER ITS APPOINTED PRIESTS AND TEACHERS, NOR ANYBODY ELSE, HAS THE CAPACITY, OR WILL TAKE THE TROUBLE, TO STAND UP FOR IT. IF THIS BE SO, THE SOONER SUCH A CIVILISATION RECEIVES NOTICE TO QUIT, THE BETTER. IT CAN ONLY GO ON FROM BAD TO WORSE, UNTIL DESTROYED AND REGENERATED (LIKE THE WESTERN EMPIRE) BY ENERGETIC BARBARIANS.

2.3 Cifra de Vigenère

Assumindo que o criptograma 1 corresponde a esta cifra com base na explicação dada anteriormente no inicio da secção, a estratégia seguida de maneira a decifrar este criptograma foi a seguinte: primeiro descobrimos o tamanho da chave (vulnerabilidade desta cifra reside na chave), para isso obtivemos as palavras com três letras que apareciam no texto (**Figura 6**) e vi-mos a diferença entre os *offsets* em que se encontravam no texto de modo a calcular a sua periodicidade e com isto vimos qual era o máximo divisor comum entre as várias diferenças obtidas, e como resultado deu-nos 5.

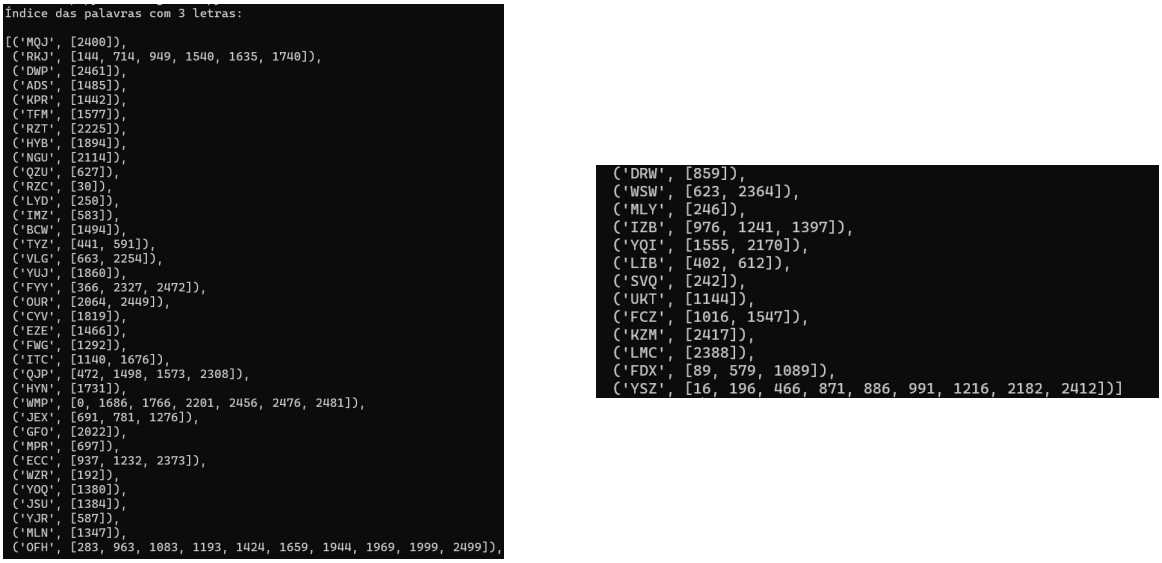

Figura 6: Frequência de palavras de tamanho 3 no criptograma 1

Após descoberta do tamanho da chave, dividimos o texto em blocos de 5 (**Figura 7**), uma vez, que pela definição de cifra de Viginère cada bloco será cifrado com a mesma chave e estes irão comportar-se como se fossem aplicados uma cifra de césar, por isso podemos aplicar como anteriormente uma análise de frequência de letras/palavras, de maneira a retirar a chave. Como WMP aparece algumas vezes assumimos que correspondia à palavra *the*, obtendo as três primeiras letras da chave **DFL** (chave parcial).

Observamos que palavra **YSZ** aparece isolada num bloco de 5(_YSZ_). Com a nossa chave parcial obtida até então, o seu resultado originava TH, e como YSZ é dos trigramas mais frequentes assumimos que correspondia à palavra *the* e com isto obtive-mos **DFLV**.

Aplicando a nova chave parcial com uma letra aleatória no fim, como por exemplo, **X**, obtivemos um texto onde existia a palavra FRPM (**Figura 8**) que advinha da sequência de letras **QMMP**, ou seja esta teria de corresponder à palavra *FROM*, de maneira a fazer sentido. Consequentemente, fomos ao bloco da palavra QMMP e o **M** encontrava-se na quinta posição, vimos qual era a letra que teria de ser para dar a letra **O** e obtivemos o **Y**, concluindo assim, que a chave era **DFLVY** .

Figura 7: Criptograma em blocos de 5

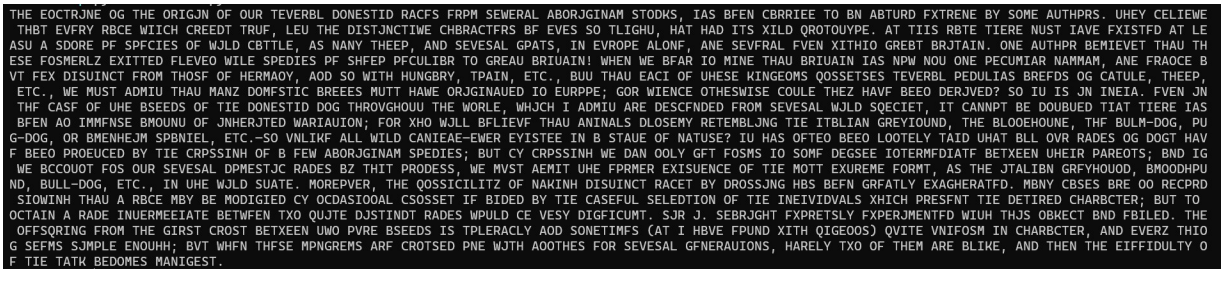

Figura 8: Decifragem com chave parcial

Com a chave DFLVY obtivemos o seguinte texto limpo:

THE DOCTRINE OF THE ORIGIN OF OUR SEVERAL DOMESTIC RACES FROM SEVERAL ABORIGINAL STOCKS, HAS BEEN CARRIED TO AN ABSURD EXTREME BY SOME AUTHORS. THEY BELIEVE THAT EVERY RACE WHICH BREEDS TRUE, LET THE DISTINCTIVE CHARACTERS BE EVER SO SLIGHT, HAS HAD ITS WILD PROTOTYPE. AT THIS RATE THERE MUST HAVE EXISTED AT LEAST A SCORE OF SPECIES OF WILD CATTLE, AS MANY SHEEP, AND SEVERAL GOATS, IN EUROPE ALONE, AND SEVERAL EVEN WITHIN GREAT BRITAIN. ONE AUTHOR BELIEVES THAT THERE FORMERLY EXISTED ELEVEN WILD SPECIES OF SHEEP PECULIAR TO GREAT BRITAIN! WHEN WE BEAR IN MIND THAT BRITAIN HAS NOW NOT ONE PECULIAR MAMMAL, AND FRANCE BUT FEW DISTINCT FROM THOSE OF GERMANY, AND SO WITH HUNGARY, SPAIN, ETC., BUT THAT EACH OF THESE KINGDOMS POSSESSES SEVERAL PECULIAR BREEDS OF CATTLE, SHEEP, ETC., WE MUST ADMIT THAT MANY DOMESTIC BREEDS MUST HAVE ORIGINATED IN EUROPE; FOR WHENCE OTHERWISE COULD THEY HAVE BEEN DERIVED? SO IT IS IN INDIA. EVEN IN THE CASE OF THE BREEDS OF THE DOMESTIC DOG THROUGHOUT THE WORLD, WHICH I ADMIT ARE DESCENDED FROM SEVERAL WILD SPECIES, IT CANNOT BE DOUBTED THAT THERE HAS BEEN AN IMMENSE AMOUNT OF INHERITED VARIATION; FOR WHO WILL BELIEVE THAT ANIMALS CLOSELY RESEMBLING THE ITALIAN GREYHOUND, THE BLOODHOUND, THE BULL-DOG, PUG-DOG, OR BLENHEIM SPANIEL, ETC.—SO UNLIKE ALL WILD CANIDAE—EVER EXISTED IN A STATE OF NATURE? IT HAS OFTEN BEEN LOOSELY SAID THAT ALL OUR RACES OF DOGS HAVE BEEN PRODUCED BY THE CROSSING OF A FEW ABORIGINAL SPECIES; BUT BY CROSSING WE CAN ONLY GET FORMS IN SOME DEGREE INTERMEDIATE BETWEEN THEIR PARENTS; AND IF WE ACCOUNT FOR OUR SEVERAL DOMESTIC RACES BY THIS PROCESS, WE MUST ADMIT THE FORMER EXISTENCE OF THE MOST EXTREME FORMS, AS THE ITALIAN GREYHOUND, BLOODHOUND, BULL-DOG, ETC., IN THE WILD STATE. MOREOVER, THE POSSIBILITY OF MAKING DISTINCT RACES BY CROSSING HAS BEEN GREATLY EXAGGERATED. MANY CASES ARE ON RECORD SHOWING THAT A RACE MAY BE MODIFIED BY OCCASIONAL CROSSES IF AIDED BY THE CAREFUL SELECTION OF THE INDIVIDUALS WHICH PRESENT THE DESIRED CHARACTER; BUT TO OBTAIN A RACE INTERMEDIATE BETWEEN TWO QUITE DISTINCT RACES WOULD BE VERY DIFFICULT. SIR J. SEBRIGHT EXPRESSLY EXPERIMENTED WITH THIS OBJECT AND FAILED. THE OFFSPRING FROM THE FIRST CROSS BETWEEN TWO PURE BREEDS IS TOLERABLY AND SOMETIMES (AS I HAVE FOUND WITH PIGEONS) QUITE UNIFORM IN CHARACTER, AND EVERY THING SEEMS SIMPLE ENOUGH; BUT WHEN THESE MONGRELS ARE CROSSED ONE WITH ANOTHER FOR SEVERAL GENERATIONS, HARDLY TWO OF THEM ARE ALIKE, AND THEN THE DIFFICULTY OF THE TASK BECOMES MANIFEST.

3 Conclusão

Dado como terminado este trabalho, este permitiu-nos aprofundar os conhecimentos obtidos nas aulas teóricas, percebendo melhor na prática as diferenças entre as várias cifras clássicas.

Concluímos que as cifras de criptografia clássica apresentam limitações, daí se encontrarem em desuso, uma vez que revelam padrões nos criptogramas gerados nos casos da cifra *affine* e de substituição, enquanto que na cifra de Viginère esta só é segura se a chave for do tamanho da mensagem, uma vez que se determinarmos o tamanho da chave esta vai ter uma periodicidade e gerar padrões no criptograma, visto que cada bloco do tamanho da chave se irá comportar como uma cifra de césar e assim adquirir as vulnerabilidades desta, por isso a sua segurança reside na chave, o que na prática não é muito eficiente, uma vez que as mensagens são grandes e com isto a chaves também terão de o ser.

Na resolução de todas as cifras, acabamos por usar "palpites"baseados nas análises de frequências como heurísticas, assim, um atacante neste tipo de cifras tem uma probabilidade alta de acertar, o que demonstra o quão importante é para um sistema criptográfico que um atacante tenha a mesma probabilidade de adivinhar ou não, isto é, um atacante não deve ter uma probabilidade melhor do que acertar aleatoriamente.

Referências

[1] Most common words in English:
https://en.wikipedia.org/wiki/Most$_c ommon_w ords_i n_E nglish$